

Identificación de conflictos en el tráfico aéreo mediante algoritmos de machine learning

Juan Mateo Camargo Vargas, Daniel Eduardo González Murillo, Laura Margarita Sandoval Bohada, María Paula Villalobos Suárez

**Escuela de Aviación del Ejército
Bogotá, Colombia**

Resumen

El incremento sostenido del tráfico aéreo ha elevado la complejidad en la gestión del espacio aéreo, aumentando el riesgo de congestión y conflictos entre aeronaves. En este estudio, se desarrolla un modelo basado en algoritmos de machine learning para la identificación y clasificación de posibles escenarios de riesgo en la navegación aérea. La investigación se centra en el espacio aéreo comprendido entre los aeropuertos de Bahía Solano, Nuquí, Quibdó y Medellín, una región caracterizada por un alto flujo de aeronaves.

El estudio se desarrolla en tres fases: La primera corresponde a la adquisición y procesamiento de datos de navegación aérea. Se emplean datos obtenidos a través de la plataforma FlightRadar24, generados por el sistema ADS-B de las aeronaves, los cuales incluyen información como identificación, posición, velocidad y rumbo. Estos datos son analizados y preprocesados para detectar patrones y caracterizar la dinámica del tráfico en la zona de estudio, la segunda fase consiste en la definición de criterios para la identificación de zonas de congestión aérea. Se establece un volumen de seguridad para cada aeronave con base en las reglas de separación mínima establecidas en los procedimientos de vuelo por instrumentos (IFR). Se considera que ocurre congestión cuando una aeronave ingresa en el volumen de seguridad de otra, lo que incrementa el riesgo de conflicto, y por último, en la tercera fase, se aplica un algoritmo de clasificación para la detección de zonas de congestión aérea. Se selecciona el algoritmo DBSCAN (Density-Based Spatial Clustering of Applications with Noise), que permite identificar regiones con alta densidad de aeronaves y diferenciarlas de las rutas de tránsito normal. Para ello, se procesan los datos considerando variables como la altitud, la velocidad y la posición geoespacial. La metodología empleada permite detectar áreas con riesgo de saturación y evaluar la distribución del tráfico en el espacio aéreo analizado.

Los resultados muestran que DBSCAN detecta con precisión zonas potenciales de conflicto, ofreciendo una herramienta efectiva para mejorar la seguridad y gestión del tráfico en regiones con alta densidad aérea.

Palabras clave: congestión aérea; conflictos aéreos; machine learning

Abstract

The sustained increase in air traffic has increased the complexity of airspace management, increasing the risk of congestion and conflicts between aircraft. In this study, a model based on machine learning algorithms is developed for the identification and classification of possible risk scenarios in air navigation. The research focuses on the airspace between the airports of Bahía Solano, Nuquí, Quibdó and Medellín, a region characterized by a high flow of aircraft. The study is carried out in three phases: The first corresponds to the acquisition and processing of air navigation data. Data obtained through the FlightRadar24 platform, generated by the aircraft's ADS-B system, is used, which includes information such as identification, position, speed and heading. These data are analyzed and preprocessed to detect patterns and characterize the traffic dynamics in the study area, the second phase consists of the definition of criteria for the identification of air congestion areas. A safety volume is established for each aircraft based on the minimum separation rules established in the instrument flight procedures (IFR). Congestion is considered to occur when one aircraft enters the safety volume of another, increasing the risk of conflict, and finally, in the third phase, a classification algorithm is applied for the detection of air congestion zones. The DBSCAN (Density-Based Spatial Clustering of Applications with Noise) algorithm is selected, which allows identifying regions with high aircraft density and differentiating them from normal transit routes. To do this, the data are processed considering variables such as altitude, speed and geospatial position. The methodology used allows detecting areas at risk of saturation and evaluating the distribution of traffic in the airspace analyzed. The results show that DBSCAN accurately detects potential conflict zones, offering an effective tool to improve safety and traffic management in regions with high air density.

Keywords: air congestion; air conflicts; machine learning

1. Introducción

El aumento constante del tráfico aéreo ha intensificado los desafíos en la gestión segura y eficiente del espacio aéreo, especialmente en zonas de alta densidad de vuelos. Esto ha generado la necesidad de implementar herramientas innovadoras como la inteligencia artificial (IA) y el aprendizaje automático (machine learning, ML), capaces de procesar grandes volúmenes de datos y generar modelos predictivos útiles. Diversos estudios recientes respaldan el uso de ML en la detección de conflictos y congestión aérea. Investigaciones de la Universidad Politécnica de Madrid (2024) demuestran que los datos ADS-B y plataformas como FlightRadar24 permiten construir modelos precisos para predecir rutas y zonas de riesgo. La Universidad Politécnica de Cataluña (2024) ha desarrollado técnicas similares para anticipar trayectorias y mejorar la gestión pre-



táctica del flujo aéreo. De igual forma, estudios liderados por Pérez-Castán Et al. (2022) evaluaron algoritmos de clasificación para detectar conflictos de forma estática, mejorando la toma de decisiones operativas. Igualmente, Salaün Et al. (2011) propusieron mapas de proximidad para identificar zonas críticas, y Weizun (2021) aplicó clustering incremental para detectar anomalías en los datos de vuelo. Además, el algoritmo DBSCAN, inicialmente usado en geolocalización volcánica, ha mostrado efectividad al aplicarse en navegación aérea según la Universidad Politécnica de Madrid. Desde una perspectiva académica y técnica, los avances en la simulación de operaciones aeroportuarias mediante plataformas como BlueSky, una herramienta de código abierto para la simulación de tráfico aéreo, desarrollada principalmente con fines educativos y de investigación, según Hoekstra Et al. (2016), junto con la implementación de modelos predictivos basados en redes neuronales artificiales, han permitido una comprensión más profunda del comportamiento del tráfico aéreo en diversos contextos. Esto resulta especialmente relevante en regiones geográficamente complejas, como el corredor Bahía Solano – Medellín, en Colombia.

Este trabajo se enmarca en dicha línea innovación, proponiendo el desarrollo de un modelo de detección de conflictos aéreos basado en ML, centrado en el corredor Bahía Solano–Nuquí–Quibdó–Medellín, un entorno idóneo por su complejidad geográfica y alto flujo de aeronaves. Estos desarrollos no solo mejoran la seguridad en zonas críticas, sino que también fortalecen la toma de decisiones de los gestores del tráfico aéreo.

2. Metodología

La investigación adoptó un enfoque cuantitativo y computacional, estructurado en tres fases: adquisición y procesamiento de datos, definición de criterios de conflicto, y aplicación de algoritmos de agrupamiento y clasificación. Este esquema permitió abordar integralmente la problemática, desde la recolección de datos confiables hasta la identificación visual de zonas críticas en el espacio aéreo del noroccidente colombiano.

En la primera fase se recopilaron y procesaron datos ADS-B de plataformas como FlightRadar24, complementados con información topográfica, meteorológica (METAR/TAF) y de rutas del AIP Colombia. El preprocesamiento incluyó limpieza, estandarización y normalización con la función StandardScaler de la librería scikit-learn. También se aplicó una heurística para asociar coordenadas a zonas de control. La segunda fase estableció los criterios de conflicto con base en el documento 4444 de la OACI (2016), que exige una separación mínima de 9.26 km horizontal y 2.000 pies vertical. Se ajustaron estos parámetros según variables como tipo de aeronave, fase de vuelo y condiciones meteorológicas. La separación estándar también fue verificada a través de fuentes complementarias como Skybrary. (S.f) donde menciona en su publicación estos estándares que concuerdan con las mencionadas anteriormente. Se desarrolló una función en Python para detectar pares de aeronaves que infringieran simultáneamente las distancias mínimas permitidas, marcando tales eventos como situaciones de riesgo. En la tercera fase se aplicó el algoritmo DBSCAN para identificar agrupamientos, por su capacidad de trabajar sin un número fijo de clústeres y su robustez ante datos ruidosos. Esta elección se fundamentó en estudios previos que evidencian su eficacia en entornos de tráfico aéreo, como el que realizó Bolić Et al (2022). Las variables latitud, longitud y altitud fueron escaladas, y se usó el coeficiente de silueta para ajustar



parámetros. Complementariamente, se exploraron algoritmos supervisados como Random Forest y SVM, con el fin de clasificar zonas según su nivel de riesgo, a partir de etiquetas generadas por el análisis de conflictos, siguiendo referencias de la Universidad Politécnica de Madrid (2024).

Para apoyar la interpretación, se crearon visualizaciones interactivas mediante la librería Folium generando mapas de calor que resaltan puntos críticos de congestión y tablas por zona aeroportuaria que incluyeron indicadores como número total de vuelos, altitudes características y frecuencia de conflictos. Esta combinación de análisis y visualización facilita la comprensión del tráfico aéreo y orienta estrategias para mitigar riesgos en regiones complejas y de alta densidad operativa.

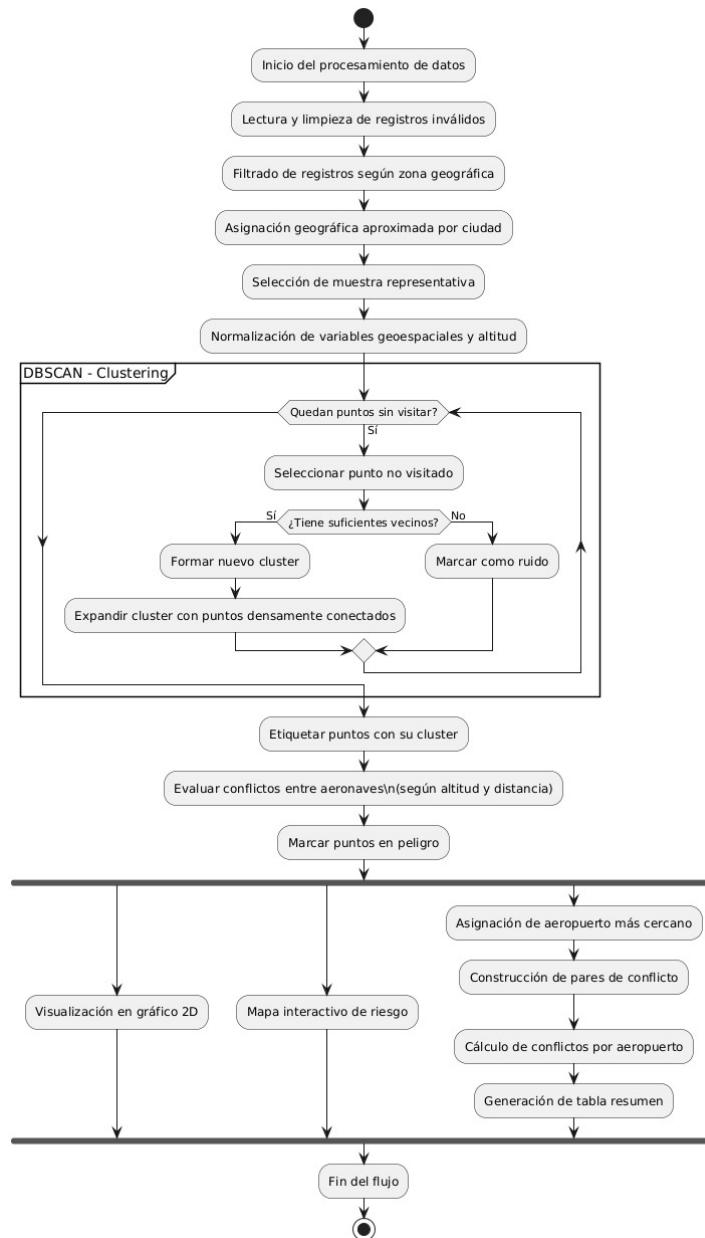


Figura 1. Descripción gráfica de la metodología.

3. Resultados

3.1. Selección del área geográfica de estudio

La región analizada corresponde al corredor aéreo entre Bahía Solano, Nuquí, Quibdó y Medellín, en el noroccidente de Colombia, como se observa en la figura 2. Esta zona fue elegida debido a que reúne diversos factores críticos tanto desde el punto de vista operacional como geográfico. En particular, se trata de un corredor que conecta la costa pacífica con un centro urbano clave del país, lo que genera un flujo constante de aeronaves civiles, militares y comerciales. Su geografía compleja, con cordilleras, selvas y clima variable, plantea desafíos para la navegación, afectando la planificación y control del tráfico aéreo. Por estas razones, el corredor resulta especialmente adecuado para estudiar eventos de congestión y posibles conflictos operacionales, tanto en contextos de alta demanda como en situaciones donde la orografía y el clima restringen las trayectorias disponibles. Además, ofrece una gran cantidad de datos ADS-B, lo que permite un análisis empírico sólido. Para facilitar el estudio, se delimitó una ventana geográfica entre las latitudes 5.0° y 7.0° norte y las longitudes -78.0° y -75.0° oeste. Esta delimitación territorial permitió trabajar con un subconjunto de datos manejable, sin perder la riqueza espacial ni la complejidad operativa del sector analizado.



Figura 2. Área geográfica y los aeropuertos de la sección estudiada.

3.2. Definición de conflicto

Para detectar conflictos en el tráfico aéreo de forma precisa, se adoptó la definición del documento 4444 de la OACI, que establece una separación mínima de 9.26 km en horizontal y 2.000 pies en vertical. Donde, un conflicto se considera cuando dos aeronaves coinciden simultáneamente dentro de ese volumen tridimensional de seguridad. Para identificar estos eventos, se desarrolló una función en Python que analiza, dentro de un conjunto de datos previamente filtrado, todas las combinaciones posibles de aeronaves presentes en intervalos cercanos, calculando automáticamente distancias horizontales (usando fórmulas geodésicas precisas) y la diferencia de altitud entre pares de vuelos. Si ambas condiciones se vulneran, el evento se registra como un conflicto en la base de datos.

3.3. Distribución espacial de vuelos y agrupamientos

La figura 3 presenta la distribución geoespacial de las aeronaves registradas dentro del área de estudio, representada mediante un gráfico de dispersión. Cada punto corresponde a una posición registrada por una aeronave, y su color indica su clasificación dentro del proceso de agrupamiento mediante el algoritmo DBSCAN. Este algoritmo permite identificar regiones con alta concentración de tráfico aéreo y diferenciar aquellas zonas que no forman parte de conglomerados densos, las cuales son clasificadas como ruido (clúster -1). El análisis revela una mayor concentración de tráfico en el oriente, especialmente cerca de los aeropuertos José María Córdova y Olaya Herrera, donde convergen múltiples rutas. Esta región muestra una estructura radial de trayectorias, resultado de rutas convergentes y salidas múltiples hacia el norte, occidente y sur del país. Por contraste, las zonas occidentales, próximas a Bahía Solano y Nuquí, presentan una dispersión más uniforme, sin concentraciones significativas, lo que indica una menor densidad operacional. La clasificación de muchos de estos puntos como ruido por el algoritmo DBSCAN sugiere que corresponden a vuelos aislados o transitorios, alejados de corredores estructurados de alta demanda. Esta representación gráfica facilita la identificación visual de focos potenciales de congestión, permitiendo inferir patrones de tránsito relevantes para la planificación táctica y la evaluación de riesgos operacionales. La segmentación automática del tráfico aéreo mediante clustering proporciona una herramienta útil para priorizar zonas en las que deben concentrarse medidas de gestión y monitoreo continuo.

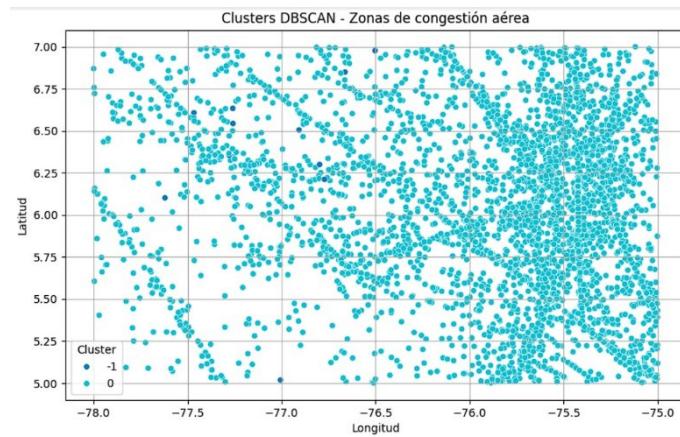


Figura 3. Clústers DBSCAN con zonas de congestión Aérea

3.4. Identificación de zonas de conflicto tridimensional

La figura 4 muestra un mapa de calor que visualiza zonas con potenciales conflictos aéreos, detectados según los criterios de separación mínima definidos por la OACI (9.26 km horizontal y 2.000 pies vertical). El análisis georreferenció los eventos de conflicto cuando ambas distancias fueron vulneradas. Las zonas en rojo indican alta frecuencia de conflictos, mientras que naranja y amarillo reflejan niveles moderados. El contorno en color azul delimita el área total cubierta por los registros analizados. Este análisis permite observar que los mayores riesgos se concentran en el centro-este del área, cerca de Medellín y Rionegro, donde confluyen múltiples rutas. También se identificaron focos sobre el corredor Nuquí-Bahía Solano, pese a que el volumen de tráfico es

menor, lo que sugiere que la complejidad geográfica o las rutas convergentes podrían estar influyendo en el comportamiento del tráfico.

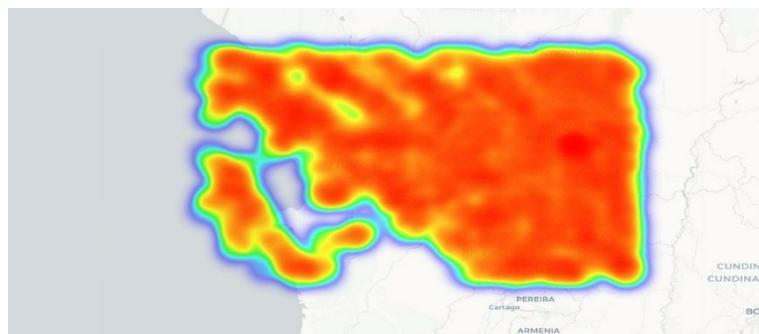


Figura 4. Heat Map General.

3.5. Conflictos puntuales por zona

El análisis detallado de los eventos de conflicto permitió identificar sectores geográficos específicos donde se concentran situaciones de riesgo operativo. Las figuras 5 y 6 muestran mapas de calor sectorizados que ilustran la distribución espacial de estos conflictos, permitiendo establecer patrones locales de alta densidad y evaluar la influencia de factores geográficos y aeroportuarios. En la figura 5, en la sección izquierda, correspondiente al corredor Medellín–Rionegro, se observa una franja de alta concentración de conflictos alineada con la aproximación y salida del Aeropuerto Olaya Herrera. Este patrón refleja la intensa actividad aérea en la zona metropolitana de Medellín y su conexión directa con rutas hacia el norte y suroccidente del país. La estrechez del valle donde se ubica el aeropuerto, sumada a la cercanía de rutas convergentes, contribuye a incrementar la criticidad del sector; mientras que la sección derecha, presenta un panorama ampliado de la zona central de Rionegro, evidenciando una alta densidad de conflictos alrededor del Aeropuerto Internacional José María Córdova. Esta región constituye uno de los nodos aéreos más importantes del país, con operaciones nacionales e internacionales que se cruzan en un espacio aéreo de complejidad topográfica. La distribución radial de los focos de conflicto coincide con las rutas de llegada y salida de esta terminal aérea, lo que refuerza la necesidad de vigilancia operativa en este entorno. En cambio, la figura 6 muestra el comportamiento en el sector Nuquí–Chocó, una zona de menor densidad de tráfico, pero con conflictos localizados de forma puntual, especialmente en áreas cercanas al litoral y a corredores de navegación sobre el océano Pacífico. Aunque el volumen de operaciones es más bajo en comparación con las zonas anteriores, la aparición de conflictos en esta región resalta la importancia de considerar no solo la cantidad de vuelos, sino también la estructura de las rutas y las limitaciones geográficas para garantizar una separación segura.

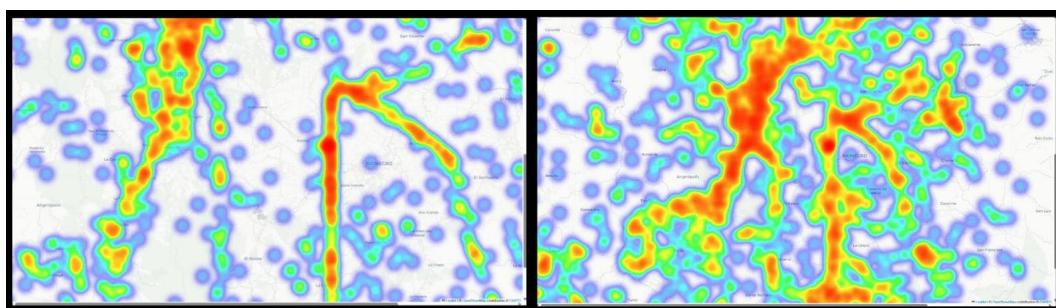


Figura 5. Heat map sectorizado por sector de Rio Negro – Medellín (Izquierda) y sectorizado en Rio Negro Central (Derecha)

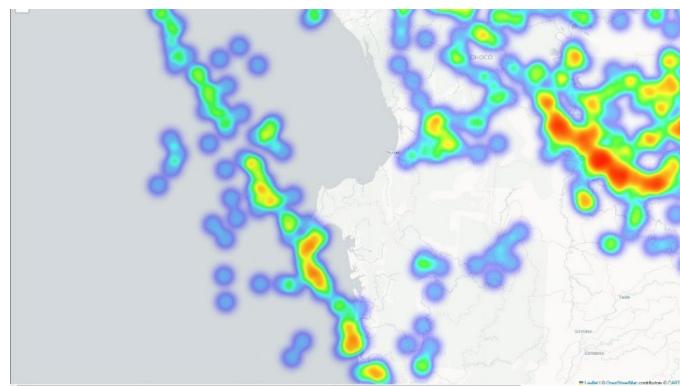


Figura 6. Heat map sectorizado por sector de Nuquí – Chocó.

3.6. Evaluación cuantitativa por zonas aeroportuarias

Para complementar el análisis espacial, se construyó la Tabla 1 la cual resume el comportamiento del tráfico aéreo y los conflictos por zonas aeroportuarias, considerando vuelos registrados, altitudes y cantidad de aeronaves involucradas en conflictos dentro de cada zona. El aeropuerto José María Córdova (SKRG) presentó la mayor actividad, con 374 vuelos y 370 aeronaves en conflicto, confirmando su papel como eje principal del tráfico aéreo regional, donde la altitud promedio de operación en este sector fue de aproximadamente 11.546 pies, con un rango que varía entre 4.875 y 40.000 pies. En segundo lugar, se encuentra el aeropuerto El Caraño (SKUI) en Quibdó, con 35 vuelos y 29 aeronaves en situación de riesgo, con una altitud media elevada (12.666 pies), posiblemente por su ubicación montañosa. El aeropuerto José Celestino Mutis (SKBS) en Bahía Solano reportó 29 vuelos y 25 aeronaves en conflicto, con una altitud promedio alta (27.080 pies), relacionada con cruces en rutas costeras. Finalmente, el aeropuerto Reyes Murillo (SKNQ) en Nuquí, aunque solo se registraron 14 vuelos, se detectaron 11 aeronaves en conflicto, lo que indica riesgos localizados importantes, especialmente en condiciones adversas o sin control aéreo.

Tabla 1. Resultados de situaciones de peligro filtrados por Aeropuertos.

Aeropuertos con situaciones de peligro (Aeronaves únicas dentro de casa zona)					
Aeropuerto	Nº Vuelos	Altitud mínima (ft)	Altitud media (ft)	Altitud máxima (ft)	Conflictos (aeronaves únicas)
SKRG (José María Córdova)	374	4875	11546,52406	40000	370
SKUI (El Caraño)	35	925	12666,42857	39000	29
SKBS (José Celestino Mutis)	29	3075	27080,17241	39000	25
SKNQ (Reyes Murillo)	14	1950	10471,42857	37000	11

4. Análisis de los resultados

4.1. Volumen de tráfico aéreo

El análisis cuantitativo mostró una alta concentración de tráfico aéreo en Rionegro, especialmente en el Aeropuerto José María Córdova (SKRG), con 374 vuelos registrados, muy por encima del resto de aeropuertos: SKUI (35), SKBS (29) y SKNQ (14). Esta diferencia destaca a Rionegro como el principal nodo aéreo del noroccidente colombiano, debido a su rol como puerta internacional y su conexión con rutas nacionales. Sin embargo, este volumen implica un reto operativo importante, aumentando el riesgo de interacción entre aeronaves y la necesidad de estrategias avanzadas de gestión y vigilancia del espacio aéreo, especialmente en condiciones complejas.

4.2. Conflictos internos por zona

El análisis de conflictos mostró una distribución desigual en el espacio aéreo. Rionegro, con alta densidad de tráfico, registró el mayor número de conflictos, con más de 30 pares de aeronaves detectadas en condiciones de separación insegura. Este hallazgo coincide con su elevada densidad de tráfico, y resalta la necesidad de fortalecer los mecanismos de vigilancia y gestión en esta área estratégica.

Por otra parte, Medellín, próximo al Aeropuerto Olaya Herrera, también presentó varios eventos, aunque en menor cantidad. Destaca el caso de Urrao, donde, pese a su tráfico moderado, se identificaron conflictos importantes, probablemente debido a su geografía y rutas convergentes. En contraste, las zonas periféricas, mostraron una menor frecuencia de conflictos internos. No obstante, se identificaron eventos cruzados en sectores como Nuquí y el litoral del Chocó, donde se detectaron conflictos cruzados de aeronaves en tránsito, lo que evidencia que el riesgo no solo depende del volumen de tráfico local, sino también de las trayectorias y condiciones del entorno.

4.3. Recomendaciones operativas

A partir de los resultados, se proponen acciones para mejorar la seguridad y eficiencia en la gestión del espacio aéreo, especialmente en zonas con alta incidencia de conflictos. Se recomienda rediseñar trayectorias y revisar procedimientos de separación en áreas como Rionegro, donde el tráfico denso y las rutas convergentes representan un riesgo. La implementación de procedimientos optimizados, acompañados de ajustes en las rutas de llegada y salida, puede contribuir a disminuir



el riesgo de interacción no segura entre aeronaves. También se sugiere implementar monitoreo permanente en regiones con geografía compleja, como Urrao y el litoral del Chocó, para anticipar escenarios peligrosos. Por último, se plantea incorporar sistemas de alerta temprana basados en algoritmos de clustering dinámico, que permitan detectar en tiempo real la formación de agrupaciones riesgosas de aeronaves y apoyar la toma de decisiones operativas.

5. Conclusiones

La investigación confirmó la viabilidad del uso de algoritmos de aprendizaje automático, especialmente DBSCAN, para detectar zonas de congestión y posibles conflictos en el espacio aéreo colombiano, utilizando datos reales de sistemas ADS-B y utilizando herramientas de análisis espacial y ciencia de datos, se construyó un modelo robusto que permite detectar agrupaciones críticas de aeronaves y evaluar su proximidad en relación con los estándares de separación establecidos por la OACI.

El modelo mostró alta precisión en áreas de alto tráfico como Rionegro y también sensibilidad para detectar riesgos en zonas de menor actividad, como Nuquí y Urrao. Esto resalta la importancia de considerar factores como rutas, trayectorias y geografía, más allá del volumen de vuelos. Además, las visualizaciones interactivas facilitaron la interpretación operativa. En conjunto, el estudio demuestra el potencial de la inteligencia artificial para modernizar la gestión del tráfico aéreo, mejorando la seguridad y eficiencia ante la creciente demanda y complejidad del espacio aéreo nacional.

6. Referencias

- Bolić, T., Castelli, L., De Lorenzo, A., & Vascotto, F. (2022). Trajectory Clustering for Air Traffic Categorisation. *Aerospace*, 9(5), 227. <https://doi.org/10.3390/aerospace9050227>
- FlightRadar24. (2024, abril). Final report: How it works. Consultado el 18 de abril de 2025 en <https://www.flightradar24.com/how-it-works>
- Hoekstra, J., & Ellerbroek, J. (2016). BlueSky ATC Simulator Project: An Open Data and Open Source Approach. In 7th International Conference on Research in Air Transportation: Philadelphia, USA.
- International Civil Aviation Organization (ICAO). (2016). Final report: Doc 4444: Air Traffic Management. Consultado el 18 de abril de 2025 en <https://www.ealts.com/documents/ICAO%20Doc%204444%20Air%20Traffic%20Management.pdf>
- Pabón, J. D. O., Zuluaga, J. A. F., & Lordui, M. P. H. (2025). Detección de anomalías en trayectorias de vuelo utilizando autoencoders y segmentación del espacio aéreo basada en regiones de Voronoi. *Revista Colombiana de Tecnologías de Avanzada*, 1(45), 82–90. <https://doi.org/10.24054/rcta.v1i45.3496>
- Pérez-Castán, J. A., Pérez-Sanz, L., Serrano-Mira, L., Saéz-Hernando, F. J., Rodríguez Gauxachs, I., & Gómez-Comendador, V. F. (2022). Design of an ATC Tool for Conflict Detection Based on Machine Learning Techniques. *Aerospace*, 9(67). <https://doi.org/10.3390/aerospace9020067>
- Python Visualization. (S.f). Final report: Folium Reference. Consultado el 18 de abril de 2025 en <https://python-visualization.github.io/folium/latest/reference.html>



- Salaün, E., Gariel, E., Vela, A., Feron, E. (2011, Febrero). Final report: Aircraft Proximity Maps Based on Data-Driven Flow Modeling. Consultado el 13 de abril de 2025 en <http://arxiv.org/pdf/1101.4957>
- Skybrary Aviation Safety. (S.f). Final report: Separation Standards. Consultado el 18 de abril de 2025 en <https://skybrary.aero/articles/separation-standards>
- Universidad Politécnica de Cataluña. (2024, febrero). Final report: Impacto de la Inteligencia Artificial en el control del tráfico aéreo: optimización, eficiencia y seguridad en la navegación aérea. <https://upcommons.upc.edu/bitstream/handle/2117/403791/memoria.pdf>
- Universidad Politécnica de Madrid. (2024, junio). Final report: Desarrollo de modelos de Machine Learning para la predicción de vuelos en el espacio aéreo español. Consultado el 10 de abril de 2025 en <https://oa.upm.es/83446/1/TFM LEONARDO AGUILAR VALAREZO.pdf>
- Universidad Politécnica de Madrid. (2023, julio). Estudio del algoritmo de clustering DBSCAN (Density Based Spatial Clustering of Applications with Noise), aplicado en la detección de cambios de las últimas erupciones del volcán Etna (Sicilia). Consultado el 10 de abril de 2025 en <https://oa.upm.es/75234/>
- Weizun Z. (2021, octubre). Final report: An Incremental Clustering Method for Anomaly Detection in Flight Data. Consultado el 13 de abril de 2025 en <https://arxiv.org/pdf/2005.09874>

Sobre los autores

- **Juan Mateo Camargo Vargas:** Estudiante de Ingeniería Aeronáutica de la Escuela de Aviación del Ejercito. juancamargovargas@cedoc.edu.co
- **Daniel Eduardo González Murillo:** Estudiante de Ingeniería Aeronáutica de la Escuela de Aviación del Ejercito. danielgonzalez@cedoc.edu.co
- **Laura Margarita Sandoval Bohada:** Estudiante de Ingeniería Aeronáutica de la Escuela de Aviación del Ejercito. laurasandovalbohada@cedoc.edu.co
- **María Paula Villalobos Suárez:** Estudiante de Ingeniería Aeronáutica de la Escuela de Aviación del Ejercito. mariavillalobos@cedoc.edu.co

Los puntos de vista expresados en este artículo no reflejan necesariamente la opinión de la Asociación Colombiana de Facultades de Ingeniería.

Copyright © 2025 Asociación Colombiana de Facultades de Ingeniería (ACOFI)

